

Compétences Techniques à Maîtriser

Guide complet des langages, frameworks, bases de données et technologies que les recruteurs attendent — avec niveaux de priorité et ressources

Comment lire ce guide ?

Chaque compétence est notée avec une priorité : ■ **Indispensable** (demandée dans 90%+ des offres), ■ **Important** (différenciateur lors des entretiens), ■ **Plus** (avantage compétitif). Les niveaux A (débutant), B (intermédiaire), C (avancé) indiquent la maîtrise attendue pour décrocher un premier poste.

1. Langages de programmation

Langage	Priorité	Niveau cible	Usage principal	Ressources
Python	■ Indispensable	Avancé (C)	Data engineering, ML, scripting, APIs	Real Python · Python.org · Fluent Python (livre)
SQL	■ Indispensable	Avancé (C)	Interrogation BDD, ETL, analytics	Mode Analytics SQL · SQLZoo · LeetCode SQL
Bash / Shell	■ Indispensable	Intermédiaire (B)	Scripts d'automatisation, CI/CD, Linux	The Linux Command Line (livre) · SS64.com
Java / Scala	■ Important	Débutant (A)	Spark natif, Kafka, JVM ecosystem	Scala Tour · Apache Spark docs
R	■ Plus	Débutant (A)	Statistiques, analyse exploratoire, bio-data	R for Data Science (Wickham) · Tidyverse
JavaScript/TypeScript	■ Plus	Débutant (A)	Dashboards web, Node.js, visualisation	Fullstack Open · D3.js tutorials

Conseil Python : maîtriser les librairies fondamentales (NumPy, Pandas, Matplotlib) n'est plus suffisant. Les recruteurs attendent maintenant : gestion d'environnements (venv/conda/poetry), code propre (PEP8, typage, docstrings), et notions de POO appliquées à la data.

2. Data Engineering & Pipelines

Apache Spark



Framework de traitement distribué. PySpark est le standard pour le Big Data.

■ Databricks Academy, Spark: The Definitive Guide

Apache Kafka



Bus de messages pour streaming temps réel. Standard de l'industrie pour les pipelines événementiels.

■ Conduktor.io, Kafka: The Definitive Guide

Apache Airflow ■ Orchestration de pipelines (DAGs). Remplace le cron, incontournable en Data Engineering. ■ <i>Astronomer.io docs, cours Marc Lamberti</i>	dbt (data build tool) ■ Transformations SQL versionnées et testées. L'outil Analytics Engineering le plus adopté. ■ <i>dbt Learn (gratuit), dbt docs</i>
Docker ■ Conteneurisation des applications data. Requis partout, même en stage. ■ <i>Play with Docker, Docker Official Docs</i>	Apache NiFi ■ Ingestion de données visuelle, low-code. Très utilisé en entreprise pour l'ETL. ■ <i>NiFi docs Apache, tutoriels Medium</i>
MinIO / AWS S3 ■ Object storage pour Data Lakes. L'API S3 est le standard universel. ■ <i>MinIO docs, AWS S3 Documentation</i>	Trino / Presto ■ Moteur de requêtes SQL distribué sur Data Lakes. Remplace les EDW coûteux. ■ <i>Trino docs, The Definitive Guide Trino</i>
Delta Lake / Apache Iceberg ■ Formats de tables transactionnelles sur Data Lake (ACID). ■ <i>Delta Lake docs, Apache Iceberg docs</i>	Great Expectations ■ Framework de qualité des données. Validation et profiling automatisés. ■ <i>greatexpectations.io/docs</i>

3. Machine Learning & Intelligence Artificielle

Bibliothèque / Framework	Priorité	Usage	Niveau pour 1er emploi
Scikit-learn	■ Indispensable	ML classique (classification, régression, clustering)	Avancé — savoir tuner et évaluer
Pandas / NumPy	■ Indispensable	Manipulation et transformation de données	Avancé — performances incluses
Matplotlib / Seaborn	■ Indispensable	Visualisation exploratoire et reporting	Intermédiaire
TensorFlow / Keras	■ Important	Deep Learning, réseaux de neurones	Débutant — comprendre les concepts
PyTorch	■ Important	Deep Learning recherche + production	Débutant à intermédiaire
HuggingFace Transformers	■ Important	NLP, LLMs, vision par ordinateur	Débutant — fine-tuning de modèles
MLflow	■ Important	Tracking expériences, registre modèles	Intermédiaire
XGBoost / LightGBM	■ Indispensable	Gradient Boosting — standard Kaggle et production	Avancé — hyperparamétrage
SHAP / LIME	■ Important	Explicabilité des modèles ML	Débutant
Plotly / Altair	■ Important	Visualisations interactives	Intermédiaire
Streamlit / Gradio	■ Indispensable	Déploiement rapide d'applis ML	Intermédiaire

Mathématiques fondamentales pour le ML

Inutile de devenir mathématicien, mais ces bases sont attendues en entretien :

Algèbre linéaire	Vecteurs, matrices, produit scalaire, valeurs propres. Fondement des réseaux de neurones et de la PCA.	■ <i>3Blue1Brown (Essence of Linear Algebra), MIT OpenCourseWare</i>
Statistiques & Probabilités	Lois de distribution, tests statistiques (t-test, χ^2), intervalles de confiance, corrélation vs causalité.	■ <i>StatQuest (YouTube), Khan Academy Statistics</i>
Calcul différentiel	Dérivées, gradient, descente de gradient. Comprendre comment les modèles apprennent.	■ <i>3Blue1Brown (Calculus), Deep Learning book Goodfellow</i>
Optimisation	Fonction de perte, régularisation (L1/L2), méthodes d'optimisation (SGD, Adam, RMSProp).	■ <i>Cours Andrew Ng (Coursera), Fast.ai</i>

4. Cloud & Infrastructure — Compétences DevOps/DataOps

La frontière entre Data Engineer et DevOps s'efface. En 2025, savoir déployer et opérer ses propres applications est indispensable, même en junior.

Conteneurisation		
Docker	■	Build, run, push images. docker-compose pour le dev local.
Kubernetes (K8s)	■	Déploiement, scaling, Services, ConfigMaps. Notions essentielles.
Helm	■	Package manager Kubernetes. Simplification des déploiements.
Cloud Providers		
AWS (Amazon Web Services)	■	S3, EC2, RDS, Lambda, EMR, Glue, SageMaker — le plus répandu.
Google Cloud Platform	■	BigQuery (incontournable pour analytics), Vertex AI, GCS.
Microsoft Azure	■	Azure Data Factory, Synapse Analytics, Azure ML.
CI/CD & Versioning		
Git & GitHub / GitLab	■	Workflow Git (branches, PRs, merges). GitHub Actions pour CI/CD.
GitHub Actions	■	Automatisation des tests, builds, déploiements. Indispensable.
DVC (Data Version Control)	■	Versionner les données et modèles ML comme du code.
Monitoring & Observabilité		
Prometheus + Grafana	■	Métriques et dashboards de monitoring. Standard industrie.
ELK Stack (Elasticsearch)	■	Logs centralisés, recherche full-text, dashboards Kibana.
Evidently AI	■	Monitoring de la dérive des données et des modèles en production.
Bases de données		
PostgreSQL	■	SGBD relationnel de référence. SQL avancé, indexation, EXPLAIN.
MongoDB	■	NoSQL document. Aggregation pipeline, indexation, schémas flexibles.
Redis	■	Cache en mémoire. File d'attente, sessions, pub/sub.
Elasticsearch	■	Recherche full-text et analytics temps réel.

Plan d'apprentissage recommandé sur 3 ans

Ce plan est indicatif et doit être adapté à ta spécialisation cible. Il suppose ~10h/semaine de travail personnel en plus des cours.

Période	Compétences prioritaires	Projets associés	Objectif
Semestre 1-2 (Débutant)	Python maîtrise (Pandas, Numpy) SQL intermédiaire Git + GitHub PostgreSQL Docker bases	Projet 01 (DVF) Projet 02 (Scraping) Projet 04 (Recommandations)	Décrocher un stage de 4-6 mois
Semestre 3-4 (Intermédiaire)	PySpark bases Apache Airflow ML intermédiaire (XGBoost, SHAP) Streamlit/FastAPI	Projet 05 (ETL Airflow) Projet 06 (Fraud) Projet 08 (DWH)	Alterner ou 1er CDI junior
Semestre 5-6 (Avancé)	Kafka, Spark Streaming MLOps (MLflow, DVC) Cloud certifications Architecture data	Projet 11 (Spark K8s) Projet 12 (IoT streaming) Projet 14 (MLOps CI/CD)	Profil confirmé 35-50k€ brut/an

Certifications reconnues par le marché

AWS Certified Data Engineer – Associate	[Amazon]
La plus demandée pour les profils Data Engineering. Tests en ligne.	■ Examens AWS + Udemy (Stephane Maarek)
Google Professional Data Engineer	[Google Cloud]
Très valorisée, couvre BigQuery, Dataflow, Pub/Sub.	■ Google Cloud Skills Boost
Databricks Certified Associate Developer for Apache Spark	[Databricks]
Reconnue dans toutes les ESN qui font du Big Data.	■ Databricks Academy (Formation gratuite)
Microsoft Azure Data Engineer Associate (DP-203)	[Microsoft]
Très demandée dans les boîtes utilisant l'écosystème Microsoft.	■ Microsoft Learn (gratuit)
dbt Analytics Engineering Certification	[dbt Labs]
Certification émergente très demandée pour profils Analytics Engineer.	■ dbt Learn (cours gratuit)

Sources : OPIIEC 2023 · Kaischool 2025 · AWS/GCP/Azure certification guides · StatQuest · 3Blue1Brown · Référentiel IDU RNCP35994.